Busca Lexical, Semântica e Híbrida com *Reranking* e RAG no NFCorpus

Trabalho Prático 2 — SCC0282 Recuperação de Informação (2º semestre de 2026)

[Nome completo do integrante 1] (Nº USP **[•••]**) **[Nome completo do integrante 2]** (Nº USP **[•••]**)
Instituto de Ciências Matemáticas e de Computação (ICMC)
Universidade de São Paulo (USP), São Carlos, SP
[email1@usp.br], [email2@usp.br]

1 Introdução

A recuperação de informação (RI) moderna raramente depende de um único sinal. Modelos lexicais como o BM25 são rápidos, interpretáveis e fortes quando consulta e documento compartilham termos, mas falham diante de sinonímia e variação de vocabulário; *bi-encoders* densos comparam significados e toleram paráfrases, porém podem diluir termos técnicos raros e truncar textos longos; *cross-encoders* avaliam consulta e documento em conjunto, com mais precisão e mais custo; e a geração aumentada por recuperação (*Retrieval-Augmented Generation*, RAG) usa os documentos recuperados como evidência para uma LLM responder [6].

Este trabalho implementa e avalia experimentalmente o pipeline completo *documentos* → *pré-processamento e indexação* → *recuperação lexical* + *semântica* → *busca híbrida* → *reranking* → *seleção de contexto* → *LLM* → *resposta* sobre o **NFCorpus** na versão do benchmark BEIR [2, 11]: 3.633 documentos médicos (título e resumo) e 3.237 consultas derivadas do NutritionFacts.org, com julgamentos de relevância graduados (0–2) e, em média, 38,2 documentos relevantes por consulta no *test*.

Objetivos. (i) construir do zero um índice invertido e a busca lexical BM25; (ii) tornar o sistema tolerante a erros ortográficos (k-gramas, Jaccard e distância de edição) e medir quanto do desempenho perdido é recuperado; (iii) recuperar semanticamente com um *bi-encoder* pré-treinado; (iv) fundir os rankings com *Reciprocal Rank Fusion* (RRF); (v) reordenar o Top-50 com um *cross-encoder*; (vi) avaliar o efeito da recuperação na qualidade das respostas de uma LLM (RAG × sem RAG). As conclusões se apoiam em avaliação quantitativa, análise por consulta e investigação de casos de sucesso e falha, sempre com valores medidos nos próprios experimentos. Todas as escolhas de modelos e parâmetros foram feitas no conjunto *dev*; o *test* só foi usado na avaliação final.

2 Metodologia

2.1 Pré-processamento

Cada documento é representado pela concatenação *título* + *espaço* + *texto* em *todos* os sistemas (lexical, semântico e reranking). Para o índice, o texto é (1) convertido para minúsculas e sem acentos (NFKD), (2) tokenizado em sequências alfanuméricas (`[a-z0-9]+`; hífens e apóstrofos separam tokens), (3) filtrado pela lista de *stopwords* do inglês do NLTK [1] e (4) reduzido ao radical pelo stemmer Snowball (Porter2) do NLTK. Consultas passam exatamente pelo mesmo pipeline. As etapas (stopwords e stemming) foram escolhidas no *dev* (Tabela 2); a lematização não foi avaliada. Uma segunda visão do texto, os *tokens normalizados antes de stopwords e stemming*, forma o dicionário da correção ortográfica (26.354 termos). Bibliotecas externas: `unicodedata/re` (biblioteca padrão) e NLTK 3.10.4.

Tabela 1: Índice invertido construído do zero.

Estatística	Valor
Documentos	3.633
Termos do vocabulário	18.958
Total de postings	359.439
Tokens indexados	602.027
Comprimento médio do documento	165,7
Construção (pré-proc. + estruturas)	0,82 s + 0,22 s
Tempo médio por consulta	0,25 ms

2.2 Índice invertido (implementado do zero)

O dicionário é um `dict` Python que mapeia cada termo a uma *posting list* formada por dois vetores de inteiros (`array('I')`) paralelos e ordenados por documento: identificadores internos e TF. O DF do termo é o comprimento da lista. Guardamos ainda o tamanho $|d|$ de cada documento (tokens após o pré-processamento) e as estatísticas globais (N, comprimento médio, vocabulário, total de *postings*). A consulta é processada *termo a termo* (*term-at-a-time*): para cada termo da consulta percorre-se apenas a sua posting list, somando as contribuições em um acumulador por documento; nunca se varre a coleção. O Top-k sai de uma seleção por `heapq` sobre os acumuladores, com desempate pelo menor identificador. A Tabela 1 traz as estatísticas do índice e os tempos de construção e de consulta.

2.3 Busca lexical: BM25

O baseline lexical é o **BM25** [10], com

$$\text{score}(q,d) = \sum_{t \in q} \text{qtf}_t \cdot \ln\!\left(1 + \tfrac{N - \text{df}_t + 0{,}5}{\text{df}_t + 0{,}5}\right) \cdot \frac{\text{tf}_{t,d}\,(k_1+1)}{\text{tf}_{t,d} + k_1\,(1 - b + b\,|d|/\overline{|d|})}.$$

Escolhemos o BM25 (e não o modelo vetorial TF-IDF/cosseno) porque a saturação do TF e a normalização por comprimento fazem diferença em resumos de tamanhos muito variados e porque é o baseline lexical padrão do BEIR, o que permite comparar os valores com a literatura. Os parâmetros $k_1 = 2{,}0$ e $b = 0{,}50$ foram escolhidos no *dev* (Tabela 3); a superfície é plana e o ganho sobre os valores usuais é pequeno. O mesmo modelo lexical é usado em todos os experimentos.

2.4 Tolerância a erros ortográficos

Correção. Um termo da consulta é *desconhecido* se for alfabético, tiver pelo menos três letras e não pertencer ao dicionário (tokens da coleção antes de stemming). Para cada termo desconhecido: (1) *candidatos* são os termos do dicionário que compartilham pelo menos um k-grama (usando um índice k-grama→termos, com marcadores de fronteira \$, $k = 2$); (2) o coeficiente de *Jaccard* entre os conjuntos de k-gramas filtra os candidatos (limiar 0,3); (3) a *distância de edição* de Damerau-Levenshtein [4, 5] (inserção, remoção, substituição e troca de adjacentes custam 1; máximo de 1) seleciona o mais próximo, com desempate por Jaccard, frequência na coleção e ordem alfabética. Os parâmetros foram ajustados no *dev* (Tabela 7).

Protocolo do experimento. Seguimos a padronização do enunciado: (i) dicionário antes do stemming; (ii) cada erro gera um termo *inexistente* no dicionário (verificado por asserção); (iii) só entram consultas com NDCG@10 original > 0 no sistema lexical; (iv) a recuperação por consulta é $\dfrac{\text{NDCG}_{corr} - \text{NDCG}_{erro}}{\text{NDCG}_{orig} - \text{NDCG}_{erro}}$ quando o denominador é positivo (senão registra-se que o erro não reduziu o desempenho). Para evitar escolha de casos favoráveis, as 10 consultas foram sorteadas (semente 42) entre as 209 consultas elegíveis do *test*, sem usar qrels além do critério (iii). Cada consulta recebe *um* erro, no termo de maior IDF (o mais informativo) com pelo menos 5 letras que não seja *stopword*; a primeira letra é preservada; os quatro tipos de erro (substituição, inserção, remoção e troca de ordem) são atribuídos em rodízio. A correção é um experimento separado: os demais usam as consultas originais.

2.5 Recuperação semântica

Usamos um *bi-encoder* `sentence-transformers/all-MiniLM-L6-v2` (MiniLM, 6 camadas [12]; arquitetura Sentence-BERT [9]) com saída de 384 dimensões, *mean pooling* e normalização L2, de modo que o produto interno é o **cosseno**. Os embeddings dos documentos são calculados uma vez e armazenados; para cada consulta calcula-se o embedding e a similaridade com *todos* os documentos (busca exaustiva, permitida pelo enunciado para esta coleção pequena). O comprimento máximo de entrada usado é **256 tokens**: os documentos têm em média 357 tokens (mediana 357; percentil 95: 558; máximo: 2377), logo **2864 documentos (78,8%) são truncados**. O limite foi escolhido no *dev* junto com o modelo (Tabela 4).

2.6 Busca híbrida: RRF

Os 100 primeiros documentos dos rankings lexical e semântico são combinados por *Reciprocal Rank Fusion* [3]: $\mathrm{RRF}(d) = \sum_s 1/(k + \mathrm{rank}_s(d))$, com posição inicial 1; documentos ausentes de um ranking não recebem contribuição desse sistema, o que evita comparar scores de escalas diferentes (BM25 e cosseno). Empates são resolvidos pela melhor posição em algum ranking e, depois, pelo identificador. O parâmetro k foi avaliado no *dev* em $\{5, 10, 20, 30, 40, 60, 80, 100, 150, 200\}$ (inclui o conjunto exigido $\{10, 60, 100\}$) e fixado em $k = 10$ por maior NDCG@10 médio (Tabela 5); o valor foi mantido no *test*.

2.7 Reranking

O ranking híbrido é o recuperador inicial. Seus 50 primeiros documentos são reordenados pelo *cross-encoder* `cross-encoder/ms-marco-MiniLM-L6-v2`, que codifica o par (consulta, documento) e produz um escore (logit) [8]; os documentos abaixo da posição 50 permanecem na mesma ordem relativa do híbrido, de modo que existe um ranking completo para as métricas. O modelo foi escolhido no *dev* (Tabela 6). O comprimento máximo do par é 512 tokens; dos 16.150 pares do *test*, 1516 (9,4%) foram truncados (média de 354 tokens por par).

2.8 RAG

Pipeline: consulta → híbrido → reranking → seleção de contexto → LLM → resposta. Cada item do corpus é uma unidade de contexto (preserva a relação com os qrels); o contexto são os **Top-5** documentos pós-reranking, com título, texto e identificador (`[MED-...]`). **Consultas:** as 10 consultas fixas do enunciado (semente 42 entre as 42 perguntas do *test*); o código reproduz exatamente a lista do enunciado (verificado por asserção). **Condições:** (A) a LLM recebe somente a pergunta; (B) pergunta + Top-5 com seus identificadores, com instruções para responder *apenas* com base no contexto, citar as fontes entre colchetes e declarar quando não houver evidência suficiente. Mesma LLM, mesmo idioma (inglês, o da coleção) e mesmo limite de 200 palavras nas duas condições. **LLM:** Claude Sonnet 5.5 (Anthropic), executado como serviço externo pela interface de chat (sem API); portanto temperatura e semente não são controláveis (amostragem padrão do serviço) e o custo foi nulo (plano de chat). O limite de saída foi de 200 palavras, pedido no *prompt*; os prompts completos e as respostas estão em `rag_experiment.csv`. As respostas da condição A foram escritas *antes* de qualquer documento recuperado ser visualizado, e as da condição B usam apenas o contexto fornecido. O código aceita outras LLMs (modelos abertos locais, APIs compatíveis com OpenAI e API da Anthropic) via `06_rag_generate.py`.

Avaliação. Na recuperação: Recall@5 (denominador = total de relevantes), Precision@5 e Hit@5. Na geração: avaliação humana estruturada (0/1/2) de fidelidade, completude, utilidade e rastreabilidade, com planilha cega e embaralhada; na condição A, a fidelidade é julgada contra os mesmos Top-5 da condição B e a rastreabilidade é "N/A" (excluída da média).

3 Avaliação

Dataset, *splits* e qrels. NFCorpus/BEIR: 3.633 documentos (campos `title` e `text`), 3.237 consultas e qrels de *train*, *dev* e *test*. As consultas de cada *split* são as que têm julgamentos no respectivo qrels (324 no *dev*; 323 no *test*, com 12.334 julgamentos, graus 1 e 2). O *dev* foi usado para escolher pré-processamento, k_1 e b, parâmetros da correção ortográfica, bi-encoder (modelo e limite de tokens), k do RRF e cross-encoder; o *test* só entrou na avaliação final, e seus qrels nunca modificaram consultas, parâmetros ou rankings. **Proveniência dos arquivos:** no ambiente de execução o servidor oficial do BEIR e o Hugging Face não estavam acessíveis; os arquivos foram obtidos de espelhos públicos no GitHub e *validados*: duas cópias independentes são idênticas em documentos, consultas e qrels; as contagens batem com as do benchmark (3.633 documentos, 3.237 consultas, 323/324 consultas no *test*/*dev*, 42 perguntas no *test*); e o código do enunciado reproduz exatamente as 10 consultas do RAG. O script `00_download_data.py` baixa o zip oficial e repete essas verificações.

Métricas. Precision@10, Recall@10, MAP@10 e NDCG@10, calculadas por consulta e depois promediadas. Para P, R e AP, relevante é todo documento com grau > 0; Recall e AP dividem pelo *total* de relevantes da consulta nos qrels; AP@10 soma $P@k$ nas posições $k \leq 10$ com relevante; NDCG@10 usa ganho linear (o grau) e ranking ideal calculado com todos os julgamentos da consulta. As quatro métricas foram implementadas no projeto e conferidas contra a `ir_measures` [7] nos quatro sistemas do *test*: a maior diferença absoluta por consulta foi $\leq 10^{-15}$. Para comparar sistemas usamos o teste de Wilcoxon pareado sobre o NDCG@10 por consulta e intervalos de confiança *bootstrap*.

Modelos e parâmetros finais. Lexical: BM25 ($k_1 = 2,0$, $b = 0,50$; stopwords removidas; stemmer Snowball (Porter2)). Semântico: `sentence-transformers/all-MiniLM-L6-v2`, máximo de 256 tokens, cosseno. Híbrido: RRF com $k = 10$ sobre os 100 primeiros de cada sistema. Reranking: `cross-encoder/ms-marco-MiniLM-L6-v2` sobre o Top-50 híbrido.

Ambiente computacional. Todos os experimentos de recuperação rodaram em CPU: Intel(R) Xeon(R) Processor @ 2.10GHz, 1 núcleo(s), 3,9 GB de RAM, sem GPU; Python 3.12.3, NumPy 2.5.4, ONNX Runtime 1.31.0, NLTK 3.10.4. Como o ambiente não tinha PyTorch nem acesso ao Hugging Face, os *mesmos pesos* dos modelos foram executados com ONNX Runtime (bi-encoder) e com uma implementação própria do encoder BERT em NumPy (cross-encoder), ambas validadas: os embeddings do bi-encoder reproduzem os gerados pelo `sentence-transformers` (cosseno $= 1{,}000000$ em 64 documentos) e o cross-encoder reproduz os escores de referência publicados no card do modelo (8,607141 e $-4{,}320078$ contra 8,607138 e $-4{,}320078$). O código também traz os *backends* do `sentence-transformers` (padrão no Colab/PC), que não foram executados neste ambiente. Os tempos reportados valem para este hardware.

Protocolo. (1) ajustes no *dev*; (2) congelamento das escolhas (`results/dev_selection.json`); (3) execução única no *test* com os mesmos Top-100 por sistema salvos em CSV; (4) análises por consulta com seleção automática dos casos (por diferença de NDCG@10), sem escolha manual.

4 Resultados Obtidos e Análise

4.1 Escolhas feitas no *dev*

Pré-processamento e BM25. Remover *stopwords* e aplicar stemming eleva o NDCG@10 do *dev* de 0,2669 (nenhuma etapa) para 0,2965 (+11%); Snowball e Porter são equivalentes (0,2965 e 0,2963). Na grade de (k_1, b) o NDCG@10 varia só entre 0,2896 e 0,2974; o ótimo ($k_1 = 2,0$, $b = 0,50$) supera os valores usuais (1,2; 0,75) em 0,0009, ou seja, a superfície é plana e o ganho é desprezível.

Bi-encoder. O melhor candidato foi o `all-MiniLM-L6-v2` com 256 tokens (0,3024; Tabela 4). Aumentar o limite para 512 tokens reduz o truncamento de 78,8% para 9,1% dos documentos e custa 58% mais tempo de codificação, mas *não* melhora o resultado (0,2956); com 128 tokens o NDCG@10 é 0,3005. Ler mais texto, portanto, não ajudou este modelo (uma possível explicação, não testada aqui, é que ele foi treinado com entradas curtas e que o título e o início do resumo concentram o sinal). O `paraphrase-MiniLM-L6-v2`, treinado para paráfrase e não para busca, é bem pior (0,2625).

Tabela 2: Pré-processamento no **dev** (BM25 com $k_1 = 1{,}2$, $b = 0{,}75$).

Stopwords	Stemming	Vocab.	P@10	R@10	MAP@10	NDCG@10
não	nenhum	26.354	0,2099	0,1099	0,0787	0,2669
sim	nenhum	26.224	0,2198	0,1113	0,0804	0,2748
não	Porter	19.004	0,2287	0,1297	0,0898	0,2905
sim	Porter	18.905	0,2364	0,1290	0,0924	0,2963
sim	Snowball	18.958	0,2364	0,1299	0,0928	0,2965

Tabela 3: NDCG@10 no **dev** para a grade de parâmetros do BM25 (melhor valor em negrito).

$k_1 \backslash b$	0,25	0,50	0,75	0,90	1,00
0,6	0,2916	0,2938	0,2929	0,2921	0,2896
0,9	0,2937	0,2949	0,2946	0,2945	0,2925
1,2	0,2948	0,2964	0,2965	0,2967	0,2939
1,5	0,2951	0,2972	0,2960	0,2956	0,2937
2,0	0,2939	**0,2974**	0,2953	0,2949	0,2941

RRF. O híbrido supera os dois sistemas isolados em *todos* os k avaliados (0,3295–0,3326 contra 0,2974 e 0,3024; Figura 1 e Tabela 5). O melhor foi $k = 10$ (0,3326); entre os valores exigidos, $k = 10, 60, 100$ dão 0,3326, 0,3307 e 0,3304: a sensibilidade a k é pequena (0,0031 entre o melhor e o pior).

Cross-encoder. Em 30 consultas do *dev* (amostra com semente fixa, limitada pelo custo de CPU), o `ms-marco-MiniLM-L6-v2` elevou o NDCG@10 do híbrido de 0,3642 para 0,3900, enquanto o L12 ficou abaixo do próprio híbrido (0,3581); o L6 foi escolhido (Tabela 6). Veremos na Seção 4.5 que esse ganho *não* se reproduziu no *test*: 30 consultas são pouco para detectar uma diferença dessa ordem.

Correção ortográfica. Em 202 consultas do *dev* com um erro gerado, o NDCG@10 caiu de 0,4489 para 0,1857 e voltou a 0,4428 com $k = 2$, Jaccard $\geq 0,3$ e distância ≤ 1: o termo exato foi recuperado em 94,6% dos casos e a recuperação média por consulta foi de 95,0%. Limiares de Jaccard maiores (0,4 e 0,5) descartam candidatos corretos (acerto de 91,6% e 85,6%). Com edição máxima 1 ou 2 o resultado é praticamente igual (0,4428 e 0,4423; Tabela 7); adotamos o critério mais conservador.

4.2 Lexical × semântico

Visão global. Em média os dois sistemas são equivalentes: NDCG@10 de 0,3303 (lexical; o BEIR reporta 0,325 para o BM25 nesta coleção [11]) e 0,3167 (semântico), diferença de $-0{,}0137$ sem significância (Wilcoxon, $p = 0{,}31$; Tabela 9); P@10 e R@10 são praticamente idênticos e o MAP@10 favorece o lexical (0,1231 contra 0,1108). A igualdade média esconde comportamentos muito diferentes por consulta: o semântico vence em 99 consultas, o lexical em 114 e há 110 empates (Figura 2), e o Top-10 dos dois sistemas tem Jaccard médio de apenas 0,20. O desencontro de vocabulário é grande: em média 60,6% dos documentos relevantes de uma consulta *não contêm nenhum* termo dela (só 10,5% contêm todos), e as consultas têm em média 2,58 termos úteis. 15 consultas do *test* (nomes de alimentos, remédios e lugares, como *eggnog*, *Fosamax*, *okra* e *Yale*) não têm nenhum termo no índice, e o lexical devolve zero resultados; 127 das 323 consultas têm menos de 100 resultados lexicais. O ganho do semântico cresce com o tamanho da consulta (Spearman entre ΔNDCG e nº de termos: $\rho = 0,18$, $p = 0,001$), mas não se relaciona de forma significativa com a fração de relevantes sem termo da consulta ($\rho = 0,07$, $p = 0,19$). O tamanho dos documentos recuperados não distingue os sistemas: o Top-10 tem em média 170 tokens no lexical e 154 no semântico, contra 166 na coleção e 167 nos relevantes.

Os seis casos (Tabelas 10–15). As três consultas com maior vantagem do semântico e as três com maior vantagem do lexical foram selecionadas automaticamente pela diferença de NDCG@10. Cada análise se apoia nos valores das tabelas e em `results/analysis/lex_vs_sem_cases.md`.

Caso 1 — *"The Difficulty of Arriving at a Vitamin D Recommendation"* (PLAIN-3085; lexical 0,000 × semântico 0,571). Os dois relevantes contêm só um dos quatro termos (*vitamin*); o BM25 recompensa as palavras raras e pouco informativas da consulta: *arriv* (idf 6,18) e *difficulti* (5,08) pesam mais que *vitamin* (2,79), e o Top-5 lexical traz, por exemplo, o MED-3632, sobre um aumento de mortalidade "após a chegada"

Tabela 4: Bi-encoders candidatos no **dev** (busca exaustiva por cosseno; "Trunc." = documentos com mais tokens que o limite).

Modelo@max_len	Max.	Trunc.	Tempo (s)	P@10	R@10	MAP@10	NDCG@10
all-MiniLM-L6-v2@128	128	97,4%	101	0,2423	0,1352	0,0956	0,3005
all-MiniLM-L6-v2@256	256	78,8%	219	0,2401	0,1364	0,0947	0,3024
all-MiniLM-L6-v2@512	512	9,1%	347	0,2346	0,1357	0,0926	0,2956
paraphrase-MiniLM-L6-v2@128	128	97,4%	188	0,2071	0,1183	0,0822	0,2625

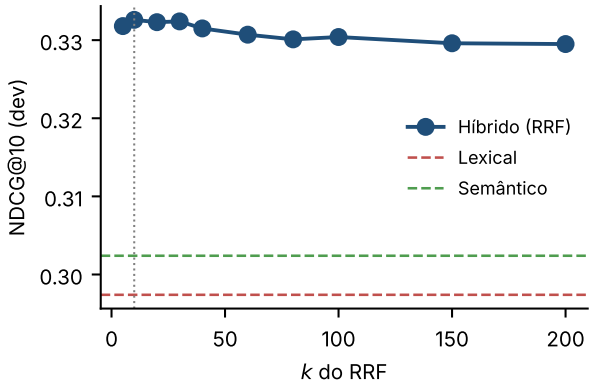


Figura 1: NDCG@10 no *dev* em função de k do RRF; linhas tracejadas: sistemas isolados.

de algo, sem relação com vitamina D. O primeiro relevante está na posição 19 no lexical e nas posições 3 e 4 no semântico (cossenos 0,635 e 0,617): o embedding capta o tema (*recomendação sobre vitamina D*) em vez de somar palavras raras. Evidência de **peso excessivo de termos raros e de paráfrase**.

Caso 2 — *"low-carb diets"* (PLAIN-1537; 0,095 × 0,662). *carb* aparece em um único documento (df = 1, idf 7,79) porque os textos escrevem *carbohydrate*: abreviação × forma plena (**variação de vocabulário e sinonímia**). Esse documento, não relevante, domina o ranking lexical (score 25,8 contra 7,4 do segundo), e os demais documentos lexicais casam só com *low* e *diet* (dietas hipocalóricas, hipoproteicas). Dos 45 relevantes, 16 não têm nenhum termo da consulta; o semântico coloca 4 relevantes no Top-5 e 6 no Top-10 (lexical: 1 e 1).

Caso 3 — *"cocaine"* (PLAIN-924; 0,220 × 0,778). Só um documento da coleção contém *cocain*; o lexical devolve apenas esse resultado (relevante, posição 1), de modo que o recall fica limitado a 1/32: 31 dos 32 relevantes não contêm o termo. O semântico mantém esse documento no topo e acrescenta textos sobre vício em comida e circuitos de recompensa (MED-3054, MED-3055, MED-3052, todos relevantes) que nunca citam cocaína: a **relevância é temática e indireta**. Há 18 relevantes no Top-100 semântico contra 1 no lexical.

Caso 4 — *"kohlrabi"* (PLAIN-1473; 1,000 × 0,000). O único relevante (MED-4455) contém o termo raro (df = 1, idf 7,79), logo o BM25 o coloca em 1º. O tokenizador do bi-encoder fragmenta *kohlrabi* em `ko ##hl ##ra ##bi`, peças sem relação com a hortaliça; os documentos devolvidos (algas, hibisco) têm cosseno máximo de 0,22 e o relevante fica fora do Top-100. Evidência a favor da **correspondência exata de termos técnicos e nomes raros**.

Caso 5 — *"shelf life"* (PLAIN-2081; 1,000 × 0,000). O relevante (MED-4303, "shelf-life evaluation of selected culinary oils") contém os dois termos e o BM25 o ranqueia em 1º (*shelf*: idf 6,18). O semântico interpreta *life* como tempo de vida: o Top-5 é sobre longevidade, restrição calórica e envelhecimento (por exemplo "Longevity and diet. Myth or pragmatism?"), e o relevante só aparece na posição 15. É um caso de **ambiguidade** (*shelf life* ≠ *life*).

Caso 6 — *"grapes"* (PLAIN-1288; 0,890 × 0,130). Dos 196 relevantes, apenas 15 contêm *grape*, mas são eles que o lexical coloca no topo (9 relevantes no Top-10). O semântico traz no Top-5 quatro documentos sobre *grapefruit* (nenhum relevante), cujo termo é segmentado em `grape ##fr ##uit`, ou seja, compartilha a peça *grape* e o domínio "fruta cítrica/fruta"; o primeiro relevante está na posição 9. Em consulta de uma só palavra, sem contexto, a **vizinhança lexical e semântica** do embedding produz ruído que a correspondência

Tabela 5: Parâmetro k do RRF no **dev**.

k	P@10	R@10	MAP@10	NDCG@10
lexical				0,2974
semântico				0,3024
5	0,2590	0,1477	0,1080	0,3318
10	0,2620	0,1482	0,1082	0,3326
20	0,2630	0,1484	0,1079	0,3323
30	0,2623	0,1506	0,1080	0,3324
40	0,2614	0,1499	0,1077	0,3315
60	0,2608	0,1497	0,1077	0,3307
80	0,2599	0,1491	0,1075	0,3301
100	0,2605	0,1495	0,1075	0,3304
150	0,2596	0,1494	0,1074	0,3296
200	0,2596	0,1494	0,1073	0,3295

Tabela 6: Escolha do cross-encoder no **dev** (amostra de consultas com semente fixa; reordena o Top-50 do híbrido).

Sistema	Consultas	P@10	R@10	MAP@10	NDCG@10
hibrido (sem reranking)	30	0,2533	0,2004	0,1526	0,3642
ms-marco-MiniLM-L6-v2	30	0,2833	0,2247	0,1601	0,3900
ms-marco-MiniLM-L12-v2	30	0,2700	0,2041	0,1374	0,3581

exata evita. (Os documentos MED-398 e MED-3207 têm o mesmo título e o mesmo cosseno, ou seja, são duplicatas na coleção.)

4.3 Tolerância a erros ortográficos

Das 209 consultas elegíveis do *test* (NDCG@10 original > 0), 10 foram sorteadas, com os quatro tipos de erro atribuídos em rodízio (3 substituições, 3 inserções, 2 remoções, 2 trocas). O NDCG@10 médio do sistema lexical foi de 0,5965 (original) para 0,0154 (com erro) e 0,5606 (corrigida): a correção recuperou 93,8% da queda (agregado) e 90,0% em média por consulta; em todas as 10 consultas o erro reduziu o NDCG@10 (nenhuma ficou sem queda), e 9 correções devolveram exatamente o termo original (Tabela 16). A queda é quase total porque várias consultas têm um ou dois termos (*fenugreek*, *salmon*, *memory*...): o erro cria um termo inexistente, com zero *postings*, e nada é recuperado.

O caso que falhou (PLAIN-711, *blood clots* → *blood colts*, troca de ordem): todos os candidatos a distância 1 são "vizinhos" do erro: *costs* (Jaccard 0,50; frequência 87), *colas*, *coats*, *colds* (0,50) e, por último, *clots* (0,33; frequência 1). A troca de duas letras adjacentes custa 1 na distância de edição, mas altera três bigramas (`ol`, `lt`, `ts`→`lo`, `ot`, `ts`), e o desempate por Jaccard e depois por frequência escolhe *costs*: NDCG@10 permanece 0 (recuperação 0%). Uma correção sensível ao contexto (*blood* coocorre com *clots*) ou um modelo de canal ruidoso resolveria o caso; não foi implementada. A amostra de 10 consultas é pequena (a de 202 consultas do *dev* dá recuperação média de 95,0%).

Sistema semântico (opcional). Com as mesmas consultas, o NDCG@10 do bi-encoder cai de 0,5173 para 0,1240 com o erro e volta a 0,4747 com a consulta corrigida (recuperação média de 87,5% nas 8 consultas em que o erro reduziu o desempenho; nas outras 2 não houve queda). Os embeddings, portanto, também são frágeis a erros de digitação: o erro altera as peças do tokenizador (*fenugreek*: `fen` `##ug` `##ree` `##k`; *feugreek*: `fe` `##ug` `##ree` `##k`), o que muda o vetor da consulta. A correção, aplicada antes da codificação, serve aos dois sistemas.

4.4 Busca híbrida

O RRF com $k = 10$ eleva o NDCG@10 do *test* para 0,3555: $+0{,}0252$ sobre o lexical ($p = 7{,}3 \times 10^{-5}$) e $+0{,}0388$ sobre o semântico ($p = 3{,}5 \times 10^{-7}$); P@10 passa a 0,2607 e R@10 a 0,1741 (Tabela 8). O híbrido é melhor que *ambos* os sistemas em 52 consultas e pior que ambos em apenas 6; nas demais 265 fica igual

Tabela 7: Parâmetros da correção ortográfica no **dev** (202 consultas com um erro gerado; NDCG@10 original = 0,4489, com erro = 0,1857).

k-grama	Jaccard	Edição máx.	Termo corrigido	NDCG@10 corrig.	Recuperação
2	0,2	1	94,6%	0,4428	95,0%
2	0,2	2	94,6%	0,4423	95,0%
2	0,3	1	94,6%	0,4428	95,0%
2	0,3	2	94,6%	0,4423	95,0%
2	0,4	1	91,6%	0,4361	92,3%
2	0,4	2	91,6%	0,4359	92,4%
2	0,5	1	85,6%	0,4255	86,9%
2	0,5	2	85,6%	0,4252	86,8%
3	0,2	1	88,6%	0,4333	91,6%
3	0,2	2	88,6%	0,4304	89,8%
3	0,3	1	77,2%	0,4135	81,6%
3	0,3	2	77,2%	0,4122	81,4%
3	0,4	1	62,9%	0,3768	68,1%
3	0,4	2	62,9%	0,3816	69,4%
3	0,5	1	49,5%	0,3478	54,0%
3	0,5	2	49,5%	0,3478	54,0%

Tabela 8: Resultados no **test** (323 consultas). IC: bootstrap percentil (10.000 reamostragens) sobre as consultas.

Sistema	P@10	R@10	MAP@10	NDCG@10	IC 95% NDCG@10
Lexical (BM25)	0,2406	0,1549	0,1231	0,3303	[0,296; 0,365]
Semântico	0,2433	0,1550	0,1108	0,3167	[0,284; 0,352]
Híbrido (RRF)	**0,2607**	**0,1741**	0,1353	0,3555	[0,321; 0,392]
Híbrido + reranking	0,2502	0,1665	**0,1388**	**0,3557**	[0,321; 0,391]

ou entre os dois. A explicação está na complementaridade medida: o Recall@100 é 0,248 no lexical, 0,312 no semântico e 0,356 na união; dos relevantes encontrados por algum sistema, 16,4% só pelo lexical, 32,9% só pelo semântico e 50,7% por ambos. O RRF premia documentos que aparecem nos dois rankings sem comparar escores de escalas diferentes (BM25 e cosseno). Um efeito colateral são os empates de RRF (um documento em 1º só no lexical e outro em 1º só no semântico têm o mesmo escore), resolvidos aqui pelo identificador, o que aparece no caso *kohlrabi* adiante.

4.5 Reranking

Resultado global. O reranking com o cross-encoder *não* melhorou o NDCG@10 do *test*: 0,3555 (híbrido) contra 0,3557 (híbrido+reranking), $\Delta = +0{,}0002$ ($p = 0{,}96$). P@10 e R@10 *caíram* (de 0,2607 para 0,2502 e de 0,1741 para 0,1665) e o MAP@10 subiu levemente (0,1353 $\rightarrow$ 0,1388). Por consulta, 100 melhoraram, 99 pioraram e 124 não mudaram (Figura 3, painel direito). Havia muito a ganhar: o Top-50 híbrido contém em média 0,267 dos relevantes e um reordenador perfeito dele alcançaria NDCG@10 de 0,581; o cross-encoder promoveu 167 relevantes das posições 11–50 para o Top-10, mas rebaixou 201 relevantes para fora dele (saldo negativo, coerente com a queda de P@10). O Top-10 pós-reranking tem documentos mais longos (177 tokens contra 160 no híbrido e 166 na coleção). O ganho de +0,026 visto no *dev* provavelmente refletia a variância de uma amostra de apenas 30 consultas. O resultado do *test* é compatível com o que o BEIR reporta para BM25 + cross-encoder MiniLM no NFCorpus (NDCG@10 de 0,350 [11]): o híbrido já chega a esse patamar sem o reranker. (Hipóteses não testadas aqui: o cross-encoder foi treinado no MS MARCO, com consultas e trechos de web, enquanto no NFCorpus a relevância é derivada de citações e muitas vezes é indireta.)

Maior ganho 1 — PLAIN-1320, *"Harvard Physicians' Study II"* (0,091 $\rightarrow$ 0,562; relevantes no Top-10: 1 $\rightarrow$ 3). O cross-encoder subiu os três relevantes sobre o *Physicians' Health Study* (MED-2760: posição 9 $\rightarrow$ 1, escore 0,755; MED-2758: 12 $\rightarrow$ 3; MED-2761: 22 $\rightarrow$ 6). O semântico havia posto esses documentos nas posições 74, 38 e 84, favorecendo textos sobre médicos em geral (posições 1 a 4: *"How evidence-based medicine biases physicians against nutrition"*, *"Physician disclosure…"*), enquanto o lexical os tinha em 2, 4 e 11. Lendo consulta e documento juntos, o reranker casou o nome próprio "Physicians' Health Study" do título; os quatro documentos que o semântico havia posto em 1º a 4º lugar foram para as posições 9, 16, 17 e

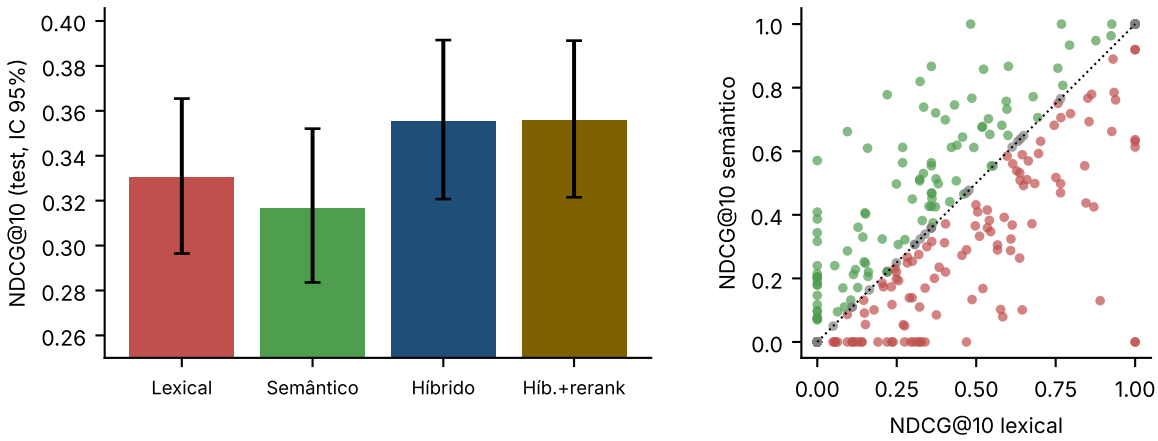


Figura 2: Esquerda: NDCG@10 no *test* por sistema (IC 95%). Direita: NDCG@10 por consulta, lexical × semântico (verde: semântico melhor; vermelho: lexical melhor; cinza: empate).

Tabela 9: Diferenças pareadas por consulta no **test** (teste de Wilcoxon de postos sinalizados).

Comparação (A vs. B)	Δ NDCG@10	A melhor/B melhor/empate	p (Wilcoxon)
Semântico vs. Lexical	-0,0137	99/114/110	0,312
Híbrido vs. Lexical	0,0252	113/77/133	$<$ 0,001
Híbrido vs. Semântico	0,0388	134/69/120	$<$ 0,001
Híbrido+rerank. vs. Híbrido	0,0002	100/99/124	0,959
Híbrido+rerank. vs. Lexical	0,0254	110/72/141	$<$ 0,001
Híbrido+rerank. vs. Semântico	0,0391	121/95/107	$<$ 0,001

Tabela 10: Caso 1 (vantagem do semântico): PLAIN-3085 — "The Difficulty of Arriving at a Vitamin D Recommendation". NDCG@10: lexical 0,000, semântico 0,571. Relevantes: 2; 0 sem nenhum termo da consulta. Colunas: relevância (0–2), score (BM25 | cosseno), posição no outro sistema, $|d|$ = tokens do documento no índice, ter = termos da consulta presentes.

#	doc	rel	BM25	r_s	$\|d\|$	ter	doc	rel	cos	r_l	$\|d\|$	ter
1	MED-3632	0	12,53	>100	153	1	MED-714	0	0,701	7	158	2
2	MED-2765	0	11,41	19	160	2	MED-4566	0	0,641	59	218	1
3	MED-919	0	11,27	5	155	2	MED-4573	2	0,635	19	135	1
4	MED-4872	0	11,16	14	170	2	MED-4570	2	0,617	47	146	1
5	MED-4104	0	10,39	>100	275	2	MED-919	0	0,611	3	155	2

Tabela 11: Caso 2 (vantagem do semântico): PLAIN-1537 — "low-carb diets". NDCG@10: lexical 0,095, semântico 0,662. Relevantes: 45; 16 sem nenhum termo da consulta. Colunas: relevância (0–2), score (BM25 | cosseno), posição no outro sistema, $|d|$ = tokens do documento no índice, ter = termos da consulta presentes.

#	doc	rel	BM25	r_s	$\|d\|$	ter	doc	rel	cos	r_l	$\|d\|$	ter
1	MED-4880	0	25,78	2	178	3	MED-4515	1	0,662	4	233	2
2	MED-2943	0	7,41	43	252	2	MED-4880	0	0,609	1	178	3
3	MED-1714	0	7,27	>100	248	2	MED-4514	1	0,596	18	308	2
4	MED-4515	1	6,97	1	233	2	MED-1616	1	0,587	43	241	2
5	MED-2458	0	6,93	>100	216	2	MED-2586	1	0,558	>100	238	2

Tabela 12: Caso 3 (vantagem do semântico): PLAIN-924 — "cocaine". NDCG@10: lexical 0,220, semântico 0,778. Relevantes: 32; 31 sem nenhum termo da consulta. Colunas: relevância (0–2), score (BM25 | cosseno), posição no outro sistema, $|d|$ = tokens do documento no índice, ter = termos da consulta presentes.

#	doc	rel	BM25	r_s	$\|d\|$	ter	doc	rel	cos	r_l	$\|d\|$	ter
1	MED-3044	1	20,43	1	217	1	MED-3044	1	0,467	1	217	1
2	-	-	-	>100	-	-	MED-3054	1	0,384	>100	128	0
3	-	-	-	>100	-	-	MED-3055	1	0,339	>100	139	0
4	-	-	-	>100	-	-	MED-3052	1	0,335	>100	139	0
5	-	-	-	>100	-	-	MED-4790	0	0,313	>100	130	0

28. (O MED-4929, também do *Physicians' Health Study II*, está em 2º e é não relevante no qrels, um sinal de julgamentos incompletos.)

Tabela 13: Caso 4 (vantagem do lexical): PLAIN-1473 — "kohlrabi". NDCG@10: lexical 1,000, semântico 0,000. Relevantes: 1; 0 sem nenhum termo da consulta. Colunas: relevância (0–2), score (BM25 | cosseno), posição no outro sistema, $|d|$ = tokens do documento no índice, ter = termos da consulta presentes.

#	doc	rel	BM25	r_s	$\|d\|$	ter	doc	rel	cos	r_l	$\|d\|$	ter
1	MED-4455	1	12,60	>100	118	1	MED-3947	0	0,220	>100	169	0
2	-	-	-	>100	-	-	MED-4660	0	0,217	>100	139	0
3	-	-	-	>100	-	-	MED-3441	0	0,216	>100	79	0
4	-	-	-	>100	-	-	MED-3447	0	0,213	>100	112	0
5	-	-	-	>100	-	-	MED-5024	0	0,212	>100	92	0

Tabela 14: Caso 5 (vantagem do lexical): PLAIN-2081 — "shelf life". NDCG@10: lexical 1,000, semântico 0,000. Relevantes: 1; 0 sem nenhum termo da consulta. Colunas: relevância (0–2), score (BM25 | cosseno), posição no outro sistema, $|d|$ = tokens do documento no índice, ter = termos da consulta presentes.

#	doc	rel	BM25	r_s	$\|d\|$	ter	doc	rel	cos	r_l	$\|d\|$	ter
1	MED-4303	1	17,36	15	181	2	MED-1378	0	0,415	54	135	1
2	MED-1182	0	12,90	>100	182	2	MED-2422	0	0,386	61	143	1
3	MED-2700	0	12,05	>100	230	2	MED-2510	0	0,386	30	121	1
4	MED-2671	0	10,15	35	100	2	MED-4715	0	0,382	>100	232	0
5	MED-2074	0	8,72	86	171	2	MED-1433	0	0,373	>100	121	0

Tabela 15: Caso 6 (vantagem do lexical): PLAIN-1288 — "grapes". NDCG@10: lexical 0,890, semântico 0,130. Relevantes: 196; 181 sem nenhum termo da consulta. Colunas: relevância (0–2), score (BM25 | cosseno), posição no outro sistema, $|d|$ = tokens do documento no índice, ter = termos da consulta presentes.

#	doc	rel	BM25	r_s	$\|d\|$	ter	doc	rel	cos	r_l	$\|d\|$	ter
1	MED-2668	1	11,68	15	108	1	MED-3200	0	0,426	>100	142	0
2	MED-2669	1	11,41	13	142	1	MED-398	0	0,425	>100	90	0
3	MED-2083	0	11,11	5	182	1	MED-3207	0	0,425	>100	90	0
4	MED-1538	1	11,10	26	183	1	MED-3210	0	0,424	>100	206	0
5	MED-1533	1	10,69	>100	183	1	MED-2083	0	0,414	3	182	1

Maior ganho 2 — PLAIN-1473, *"kohlrabi"* (0,631 → 1,000). O único relevante já estava em 2º no híbrido: o 1º era o MED-3947 (hibisco), com o mesmo escore RRF $1/(10+1)$ do relevante (1º só no semântico $\times$ 1º só no lexical); o desempate por identificador favoreceu o irrelevante. O cross-encoder deu +1,22 ao MED-4455 (que contém o termo) contra −4,31 ao seguinte. O "ganho" é a correção de um empate do RRF, e o semântico não tinha informação sobre *kohlrabi* (Caso 4).

Pouca ou nenhuma alteração — PLAIN-1557, *"magnesium"* ($\Delta = 0$). Os três relevantes continuam no Top-10 (posições híbridas 3, 2 e 9; finais 2, 3 e 9): só trocaram de lugar os dois primeiros, ambos com grau 1, o que não altera o NDCG. Cinco posições do Top-10 mudam, mas por documentos não relevantes que entram vindo de mais fundo (MED-3497: 27 → 7). Todos os documentos do topo já continham o termo *magnesium*, de modo que o reranker não tinha sinal novo para separá-los.

Piora — PLAIN-1679, *"myelopathy"* (0,387 → 0,000). A palavra não existe no índice (df = 0): o híbrido é só o ranking semântico, que põe o único relevante (MED-5142, degeneração combinada subaguda da medula espinhal) na posição 5. O cross-encoder o rebaixa para a 40ª (escore −10,2) e coloca no topo textos sobre *mieloma múltiplo* (por exemplo o MED-1105, escore 0,193): *myelopathy* e *myeloma* compartilham as peças `my` `##elo` no tokenizador, e o documento relevante nunca usa a palavra da consulta. O modelo, treinado em passagens de web, não conhece a relação clínica e se apoia na forma da palavra.

4.6 Tempos

Medidos em CPU de um único núcleo (Tabela 21): o índice invertido é construído em 1,23 s e responde em 0,25 ms por consulta; os embeddings dos documentos levam 219 s e a consulta semântica, 3,5 ms; a fusão RRF custa 0,102 ms. O reranking de 50 pares leva 12,3 s por consulta (0,246 s por par, com média de 354 tokens por par), muito mais que todo o restante junto, e foi implementado com NumPy puro em CPU; em GPU o custo seria muito menor, mas a proporção entre as etapas deve se manter. Sem reranking, a consulta híbrida completa leva cerca de 4 ms.

Tabela 16: Experimento de tolerância a erros (sistema lexical, **test**). Recup. = (corrigida − erro)/(original − erro).

Consulta	Tipo de erro	Original	Com erro	Corrigido	NDCG orig.	NDCG erro	NDCG corr.	Recup.
PLAIN-344	substituição	`dioxins`	`diofins`	`dioxins`	0,417	0,000	0,417	100%
PLAIN-1527	inserção	`liver`	`livwer`	`liver`	0,768	0,069	0,768	100%
PLAIN-1172	remoção	`fenugreek`	`feugreek`	`fenugreek`	0,220	0,000	0,220	100%
PLAIN-711	troca	`clots`	`colts`	`costs`	0,359	0,000	0,000	0%
PLAIN-2124	substituição	`spearmint`	`skearmint`	`spearmint`	0,359	0,000	0,359	100%
PLAIN-2040	inserção	`salmon`	`saglmon`	`salmon`	0,751	0,000	0,751	100%
PLAIN-1983	remoção	`rapamycin`	`raamycin`	`rapamycin`	1,000	0,000	1,000	100%
PLAIN-1601	troca	`memory`	`mmeory`	`memory`	0,581	0,000	0,581	100%
PLAIN-701	substituição	`raspberries`	`raspberrieh`	`raspberries`	0,510	0,084	0,510	100%
PLAIN-1473	inserção	`kohlrabi`	`kohlrrabi`	`kohlrabi`	1,000	0,000	1,000	100%

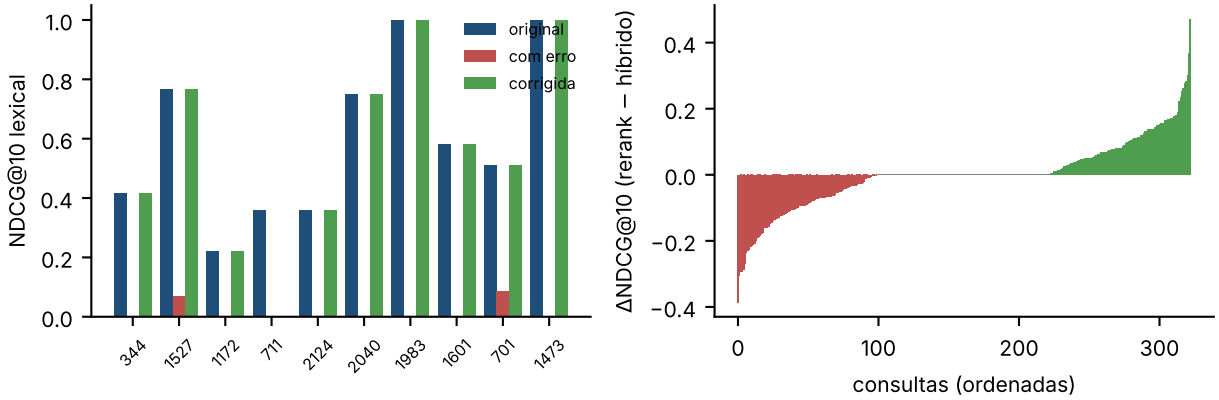


Figura 3: Esquerda: NDCG@10 lexical nas 10 consultas do experimento de erros. Direita: ΔNDCG@10 por consulta do reranking (híbrido+reranking − híbrido), ordenado.

Tabela 17: Reranking, caso 1 (maior ganho 1): PLAIN-1320 — "Harvard Physicians' Study II". NDCG@10: híbrido 0,091 → 0,562. Documentos do Top-10 (antes ou depois) com maior deslocamento, ordenados pela posição final. Δ = posição híbrida − posição final.

rank CE	rank híb.	Δ	doc	rel	score CE	r_{lex}	r_{sem}	$\|d\|$	ter
5	19	+14	MED-4398	0	-4,21	5	>100	157	3
6	22	+16	MED-2761	1	-5,36	11	84	205	3
7	26	+19	MED-3932	0	-6,24	10	>100	188	3
8	46	+38	MED-5124	0	-7,14	24	>100	205	2
10	39	+29	MED-1622	0	-7,52	21	>100	184	3
16	1	-15	MED-1053	0	-8,55	6	4	144	2
17	3	-14	MED-1097	0	-8,66	14	3	86	1
28	2	-26	MED-2112	0	-9,78	17	1	64	2

Tabela 18: Reranking, caso 2 (maior ganho 2): PLAIN-1473 — "kohlrabi". NDCG@10: híbrido 0,631 → 1,000. Documentos do Top-10 (antes ou depois) com maior deslocamento, ordenados pela posição final. Δ = posição híbrida − posição final.

rank CE	rank híb.	Δ	doc	rel	score CE	r_{lex}	r_{sem}	$\|d\|$	ter
4	48	+44	MED-1686	0	-6,73	>100	47	106	0
7	45	+38	MED-2135	0	-8,07	>100	44	197	0
9	36	+27	MED-712	0	-8,42	>100	35	186	0
40	10	-30	MED-744	0	-10,23	>100	9	124	0
41	6	-35	MED-5024	0	-10,24	>100	5	92	0
43	7	-36	MED-4385	0	-10,38	>100	6	87	0
44	3	-41	MED-4660	0	-10,43	>100	2	139	0
47	4	-43	MED-3441	0	-10,89	>100	3	79	0

4.7 RAG

Recuperação (Top-5 pós-reranking enviado à LLM). Pelo menos um documento relevante chegou ao contexto em 9 das 10 consultas (Hit@5 = 0,9), com Precision@5 médio de 0,4600 e Recall@5 médio de 0,1075 (Tabela 22). O Recall@5 baixo é esperado: as consultas têm em média 43,6 relevantes, então 5 documentos cobrem no máximo cerca de 11,5%. O caso extremo é PLAIN-153 (*How Should I Take Probiotics?*), em que os 5 documentos são relevantes; a exceção é PLAIN-2850 (*More Antibiotics In White*

Tabela 19: Reranking, caso 3 (pouca/nenhuma alteração): PLAIN-1557 — "magnesium". NDCG@10: híbrido 0,315 → 0,315. Documentos do Top-10 (antes ou depois) com maior deslocamento, ordenados pela posição final. Δ = posição híbrida − posição final.

rank CE	rank híb.	Δ	doc	rel	score CE	r_{lex}	r_{sem}	$\|d\|$	ter
2	3	+1	MED-3918	1	-0,53	3	3	98	1
3	2	-1	MED-4315	1	-1,36	4	2	82	1
5	11	+6	MED-5005	0	-2,69	7	>100	259	1
7	27	+20	MED-3497	0	-3,80	16	>100	180	1
8	41	+33	MED-2249	0	-3,90	23	>100	237	1
15	7	-8	MED-1844	0	-5,36	>100	5	167	0
30	5	-25	MED-1110	0	-7,06	>100	4	139	0
34	8	-26	MED-1843	0	-7,97	>100	6	143	0

Tabela 20: Reranking, caso 4 (piora): PLAIN-1679 — "myelopathy". NDCG@10: híbrido 0,387 → 0,000. Documentos do Top-10 (antes ou depois) com maior deslocamento, ordenados pela posição final. Δ = posição híbrida − posição final.

rank CE	rank híb.	Δ	doc	rel	score CE	r_{lex}	r_{sem}	$\|d\|$	ter
1	32	+31	MED-1105	0	0,19	>100	32	83	0
2	24	+22	MED-1104	0	-0,93	>100	24	62	0
6	19	+13	MED-1111	0	-2,88	>100	19	195	0
9	2	-7	MED-1113	0	-4,11	>100	2	185	0
10	39	+29	MED-4312	0	-5,22	>100	39	77	0
15	7	-8	MED-3302	0	-7,58	>100	7	111	0
37	1	-36	MED-5133	0	-9,98	>100	1	89	0
40	5	-35	MED-5142	1	-10,20	>100	5	129	0

Meat or Dark Meat?), sem nenhum relevante no contexto.

Geração: configuração e verificações objetivas. A LLM é a descrita na Metodologia; as respostas têm em média 171 palavras na condição A e 163 na B. As respostas B citam 48 documentos no total, **todos presentes no contexto enviado** (48 de 48, nenhum identificador inventado); 21 das citações apontam para documentos relevantes no qrels, porque várias respostas citam documentos irrelevantes justamente para dizer que eles não tratam da pergunta (23 dos 50 documentos do contexto são relevantes). As respostas A não têm fontes (0 identificadores), como previsto. Estas verificações automáticas *não substituem* a avaliação humana.

Avaliação humana (Tabela 23). [A preencher pelos integrantes: avaliar a planilha cega (results/rag_annotation_sheet.csv) com o script 07 e atualizar esta tabela e o texto abaixo. Discutir as médias A × B por critério, a concordância entre avaliadores e a ausência de fontes na condição A (rastreabilidade N/A).]

4.8 Análise de falhas ponta a ponta

[Escolher, depois das notas, três consultas: (1) o RAG melhorou claramente a resposta; (2) pouca diferença; (3) o RAG não ajudou ou prejudicou. Para a (3), localizar o estágio do problema (lexical, semântico, fusão, reranking, seleção de contexto ou geração) com results/analysis/rag_failure_traces.md.]
Evidência já disponível para um candidato à categoria (3): PLAIN-2850. Existem 9 relevantes no qrels e nenhum chegou ao Top-10 em nenhuma etapa: em cada sistema só 2 deles estão no Top-100 e o primeiro relevante aparece na posição 77 (lexical), 14 (semântico), 38 (híbrido) e 16 (reranking). A informação necessária, portanto, nunca chegou ao contexto: o problema está na **recuperação** (os dois recuperadores falham e a fusão e o reranking não os salvam), não na geração. A resposta B declara que o contexto não tem evidência suficiente, o que é fiel ao contexto, mas pouco útil; os documentos recuperados tratam de resistência bacteriana em carnes de varejo, bacteriófagos e consumo de carne e doenças, sem comparar carne branca e escura. Confirme a classificação com as notas.

4.9 Limitações

(i) A escolha do cross-encoder usou só 30 consultas do *dev* e não se confirmou no *test*. (ii) O experimento de erros usa 10 consultas e um erro por consulta; o *dev* (202 consultas) corrobora o resultado. (iii) Os qrels do NFCorpus são incompletos e derivados de citações (por exemplo, o MED-4929 é tematicamente adequado ao caso PLAIN-1320, mas não é relevante), o que subestima todos os sistemas. (iv) Cada sistema foi executado

Tabela 21: Tempos medidos (CPU: Intel(R) Xeon(R) Processor @ 2.10GHz, 1 núcleo(s), sem GPU).

Etapa	Tempo	Frequência
Índice invertido (pré-processamento + estruturas)	1,23 s	uma vez
Embeddings dos documentos (3.633)	219 s	uma vez
Consulta lexical (pré-proc. + BM25 + Top-100)	0,25 ms	por consulta
Consulta semântica (codificação + busca exaustiva)	3,5 ms	por consulta
Fusão RRF (100 + 100 documentos)	0,102 ms	por consulta
Reranking (cross-encoder, 50 pares)	12,3 s	por consulta

Tabela 22: RAG: recuperação nos Top-5 enviados à LLM (após reranking). "Graus no Top-5" = relevância de cada documento do contexto (0 = não relevante/não julgado).

Consulta	Pergunta	Rel. total	Graus no Top-5	R@5	P@5	Hit@5
PLAIN-68	What is Actually in Chicken Nuggets?	55	2 0 0 0 0	0,018	0,20	1
PLAIN-2450	Are Organic Foods Safer?	38	0 2 0 0 2	0,053	0,40	1
PLAIN-153	How Should I Take Probiotics?	47	2 1 1 1 1	0,106	1,00	1
PLAIN-2850	More Antibiotics In White Meat or Dark Meat?	9	0 0 0 0 0	0,000	0,00	0
PLAIN-2750	Preventing the Common Cold with Probiotics?	59	2 1 2 1 0	0,068	0,80	1
PLAIN-270	Is Caffeinated Tea Really Dehydrating?	52	1 0 0 0 1	0,038	0,40	1
PLAIN-2470	Is Milk Good for Our Bones?	73	2 2 2 0 0	0,041	0,60	1
PLAIN-2430	Preventing Brain Loss with B Vitamins?	46	2 2 0 2 0	0,065	0,60	1
PLAIN-238	How Chemically Contaminated Are We?	54	0 1 0 0 0	0,018	0,20	1
PLAIN-3342	Is Coconut Milk Good For You?	3	2 0 0 0 2	0,667	0,40	1
Média				0,107	0,46	0,9

uma vez, sem repetições. (v) A LLM do RAG foi usada por interface de chat, sem controle de temperatura ou semente. (vi) Tempos medidos em uma CPU de um núcleo.

5 Considerações Finais

(1) Lexical e semântico são equivalentes em média e complementares por consulta. BM25 e bi-encoder têm NDCG@10 de 0,3303 e 0,3167 no *test* (diferença sem significância), mas ganham em consultas diferentes: o lexical vence quando há termo raro ou nome próprio (*kohlrabi*, *shelf life*, *grapes*), e o semântico quando há sinonímia, abreviação, relevância indireta ou palavras raras sem valor temático (*low-carb*, *cocaine*, *vitamin D recommendation*). Os Top-10 se sobrepõem pouco (Jaccard 0,20). **(2) O RRF é a melhoria mais barata e consistente:** $+0{,}025$ de NDCG@10 sobre o lexical e $+0{,}039$ sobre o semântico, com sensibilidade pequena a k e custo de décimos de milissegundo. **(3) A correção ortográfica funciona, mas é frágil em empates:** recuperou 93,8% da queda de NDCG@10 nas 10 consultas do *test* (95% no *dev*); a única falha foi uma troca de letras cujo candidato correto perdeu no desempate por Jaccard e frequência. Os embeddings também sofrem com erros de digitação. **(4) O reranking com o cross-encoder MS MARCO MiniLM não compensou o custo neste experimento:** NDCG@10 de 0,3555 para 0,3557 ($p = 0{,}96$), P@10 menor, e 12,3 s por consulta em CPU. Há margem (oráculo de 0,581 no Top-50), mas o modelo a aproveita mal; vale testar um cross-encoder treinado no domínio biomédico e mais consultas do *dev* na escolha. **(5) RAG:** a recuperação entregou ao menos um relevante ao contexto em 9 de 10 consultas, e a única exceção (PLAIN-2850) é uma falha de recuperação, não de geração. **[Concluir, após a avaliação humana, o efeito do RAG na fidelidade, completude, utilidade e rastreabilidade.]** **Trabalhos futuros:** correção sensível ao contexto, expansão de consultas para termos fora do vocabulário (nomes de remédios, alimentos e lugares), fusão ponderada ou aprendida, reranker específico de domínio e avaliação do RAG com mais consultas e mais de uma LLM.

6 Uso de ferramentas de IA

IA como componente do experimento (documentada na Metodologia): o bi-encoder `sentence-transformers/all-MiniLM-L6-v2`, o cross-encoder `cross-encoder/ms-marco-MiniLM-L6-v2` e a LLM do RAG. **IA como apoio ao desenvolvimento:** usamos o assistente Claude (Anthropic) para escrever e depurar o código do projeto (índice invertido, BM25, correção ortográfica, métricas, scripts e testes), planejar e executar os

Tabela 23: RAG: médias das notas da avaliação humana (0–2) por condição. **PENDENTE**: preencher após a avaliação humana (script 07).

Condição	Fidelidade	Completude	Utilidade	Rastreabilidade
A (sem RAG)	*a preencher*	*a preencher*	*a preencher*	N/A
B (com RAG)	*a preencher*	*a preencher*	*a preencher*	*a preencher*

experimentos, gerar tabelas e figuras, rascunhar o texto deste relatório e as análises por consulta a partir das evidências numéricas produzidas pelo código, e redigir as respostas das duas condições do experimento de RAG. Os integrantes revisaram o código, os resultados e o texto e são responsáveis por compreendê-los e defendê-los. A avaliação humana do RAG (notas de 0 a 2) cabe aos integrantes e não foi delegada à IA.

Referências

[1] Steven Bird, Ewan Klein, and Edward Loper. *Natural Language Processing with Python*. O'Reilly Media, 2009.

[2] Vera Boteva, Demian Gholipour, Artem Sokolov, and Stefan Riezler. A full-text learning to rank dataset for medical information retrieval. In *Advances in Information Retrieval (ECIR 2016)*, volume 9626 of *LNCS*, pages 716–722. Springer, 2016.

[3] Gordon V. Cormack, Charles L. A. Clarke, and Stefan Büttcher. Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. In *Proceedings of SIGIR*, pages 758–759, 2009.

[4] Fred J. Damerau. A technique for computer detection and correction of spelling errors. *Communications of the ACM*, 7(3):171–176, 1964.

[5] Vladimir I. Levenshtein. Binary codes capable of correcting deletions, insertions, and reversals. *Soviet Physics Doklady*, 10(8):707–710, 1966.

[6] Patrick Lewis, Ethan Perez, Aleksandra Piktus, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.

[7] Sean MacAvaney, Craig Macdonald, and Iadh Ounis. Streamlining evaluation with ir-measures. In *Advances in Information Retrieval (ECIR 2022)*, 2022.

[8] Rodrigo Nogueira and Kyunghyun Cho. Passage re-ranking with BERT. *arXiv preprint arXiv:1901.04085*, 2019.

[9] Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using siamese BERT-networks. In *Proceedings of EMNLP-IJCNLP*, 2019.

[10] Stephen Robertson and Hugo Zaragoza. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009.

[11] Nandan Thakur, Nils Reimers, Andreas Rücklé, Abhishek Srivastava, and Iryna Gurevych. BEIR: A heterogeneous benchmark for zero-shot evaluation of information retrieval models. In *NeurIPS Datasets and Benchmarks Track*, 2021.

[12] Wenhui Wang, Furu Wei, Li Dong, Hangbo Bao, Nan Yang, and Ming Zhou. MiniLM: Deep self-attention distillation for task-agnostic compression of pre-trained transformers. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.